



COMILLAS

UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Sprint 1

Grupo:

Jorge Carnicero Príncipe,

Andrés Gil Vicente,

Jorge González Pérez

Tecnologías de Procesamiento Big Data

3º Grado en Ingeniería Matemática e Inteligencia Artificial

Índice

Índice.....	2
1. Respuesta a HU-1: Fuente de Datos y Alcance.....	3
1.1. Análisis Exploratorio de los Datos (EDA).....	3
2. Respuesta a HU-2: Diseño de la Arquitectura de Almacenamiento.....	6
2.1. Estrategia de Bucket Único.....	6
2.2. Jerarquía de Objetos (Partitioning).....	7
2.3. Formato de Archivo.....	7
3. Implementación Técnica (Lógica del Script complete.py).....	7
3.1. Smart Caching y Carga Incremental.....	7
3.2. Gestión Automática del Ciclo de Vida (Retention).....	8
3.3. Idempotencia en Infraestructura.....	8
4. Resultados y Evidencias.....	8
4.1. Bucket y Estructura en S3.....	8
4.2. Validación de Datos.....	10
4.3. Logs de Ejecución.....	10
5. Conclusión.....	10


1. Respuesta a HU-1: Fuente de Datos y Alcance

Para cumplir con los requerimientos de negocio respecto a la obtención de datos, hemos establecido la siguiente configuración de extracción:

- **Herramienta:** Script propio en Python integrando la librería [TradingView-Data](#).
- **Fuente de Datos:** Exchange **BINANCE**. Se ha seleccionado por ser el exchange con mayor volumen y consistencia histórica para los pares **USD**.
- **Ventana Temporal:** 4 años de histórico (retención dinámica configurada en código).
- **Frecuencia:** Datos diarios (**1D**).
- **Flexibilidad de acceso a Datos:** El script nos permite elegir la criptomoneda que queramos, permitiendo que el sistema sea escalable por si quisiéramos acceder a datos de más monedas, en nuestro caso únicamente queremos la de SOLANA - SOLUSD.

1.1. Análisis Exploratorio de los Datos (EDA)

Se ha realizado un análisis exploratorio exhaustivo de los datos cargados para validar su calidad y detectar posibles anomalías. El análisis se ha documentado en el notebook Jupyter [eda.ipynb](#), que procesa el asset SOLUSD (Solana) descargado de TradingView.



Normalización y Preparación:

Los datos se normalizaron convirtiendo el índice temporal a [DatetimeIndex](#) y eliminando información de zona horaria para simplificar el análisis diario. Posteriormente, se consolidaron los datos por fecha aplicando agregaciones apropiadas: el precio de apertura corresponde al primer valor del día, el máximo y mínimo se calculan como el high y low del día respectivamente, el precio de cierre es el último valor del día, y el volumen se suma para obtener el total diario. El dataset resultante contiene 1,460 registros diarios que abarcan desde el 24 de enero de 2022 hasta el 22 de enero de 2026, cumpliendo con el requisito de aproximadamente 4 años de datos históricos.

Validaciones de Integridad:

La estructura del dataset confirmó la presencia de todas las columnas esperadas: symbol, open, high, low, close y volume. Todos los campos numéricos se convirtieron correctamente a tipo float64 y no se detectaron valores nulos en ninguna columna. El análisis de integridad del símbolo confirmó que todos los 1,460 registros corresponden a BINANCE:SOLUSD sin duplicados por datetime. Se validaron las reglas de coherencia OHLC verificando que el precio high sea siempre mayor o igual al máximo entre open y close, que el precio low sea menor o igual al mínimo entre open y close, que high sea mayor o igual a low, que todos los precios sean positivos, y que los volúmenes sean no negativos. Todos los registros cumplieron estas reglas sin excepciones.

Cobertura Temporal:

El análisis de cobertura temporal demostró que el dataset es completo, sin días faltantes en el rango entre la fecha mínima y máxima. Los 1,460 días esperados están presentes en su totalidad. Adicionalmente, se verificó la cobertura de fines de semana confirmando que los 416 días de sábado y domingo esperados en el período están todos presentes, validando que el mercado de criptomonedas opera de forma continua 24/7. El análisis mensual reveló cobertura completa de todos los meses en el rango, con dos meses parciales como es esperado: enero 2022 (desde el día 24) y enero 2026 (hasta el día 22). No se detectaron meses completos faltantes ni días ausentes dentro de los meses parciales.

Estadísticas y Comportamiento del Mercado:


El precio de cierre de SOLUSD presenta un rango amplio desde un mínimo de \$9.64 hasta un máximo de \$261.72, con un precio medio de \$103.06 y una desviación estándar de \$69.28. Esta desviación representa aproximadamente el 67% del precio medio, evidenciando la alta volatilidad característica del mercado de criptomonedas. El volumen promedio diario es de 326,241 unidades, con picos excepcionales de hasta 4.5 millones de unidades. Los cinco precios de cierre máximos se concentran en el período de noviembre 2024 a enero 2025, con el máximo absoluto de \$261.72 alcanzado el 18 de enero de 2025, sugiriendo un rally alcista reciente. Por otro lado, los cinco días con mayor volumen de transacciones se concentran en buena medida en noviembre de 2022, en un contexto de fuertes caídas de precio asociado al colapso de FTX, lo que sugiere un aumento notable de la actividad del mercado en periodos de pánico. Aun así, también se observan picos relevantes fuera de ese mes, como un máximo puntual a finales de 2023 y otro a comienzos de 2025, indicando que los repuntes del volumen no se limitan a un único evento y pueden aparecer tanto en fases de estrés como en momentos de alta atención al mercado.

Detección de Outliers:


Se aplicó un análisis de outliers calculando el z-score sobre los log-returns diarios y utilizando un umbral de 6 desviaciones estándar. Se detectó un único outlier el 9 de noviembre de 2022, con un log-return de -0.551 que corresponde a una caída del precio de aproximadamente 42% en un solo día. Este evento coincide con el colapso del exchange FTX, un hecho histórico documentado que causó pánico generalizado en el mercado de criptomonedas. El outlier es legítimo y refleja un evento de mercado real, no un error de datos.

Visualizaciones Principales:


También se incluyen tres gráficos que ilustran el comportamiento temporal de SOLUSD:



La primera muestra la serie temporal del precio de cierre junto con una media móvil de 30 días y bandas de volatilidad de ± 2 desviaciones estándar, superpuesta con el volumen de trading. En esta gráfica se observan varios ciclos de volatilidad con períodos de consolidación seguidos de movimientos bruscos, donde los picos de volumen coinciden consistentemente con movimientos de precio significativos. Las bandas de volatilidad se expanden notablemente durante períodos de alta incertidumbre, particularmente en noviembre 2022 y enero 2025. La tendencia general muestra una recuperación sostenida desde los mínimos de 2022 hacia nuevos máximos históricos en el período 2024-2025.



El segundo gráfico es un heatmap de retornos mensuales que visualiza el rendimiento mes a mes. Destacan, por un lado, la subida excepcional de enero de 2023 (+139,7%), que representa el mayor retorno mensual del periodo, y por otro, la fuerte caída de noviembre de 2022 (-56,0%), asociada a un episodio de estrés del mercado (colapso de FTX). El comportamiento entre 2023 y 2024 es bastante variante, mientras que en 2025 parece más estable. En conjunto, no se aprecia un patrón estacional estable; los retornos alternan meses muy positivos y muy negativos, lo que sugiere que los movimientos responden más a eventos del mercado que a ciclos temporales predecibles.



El tercer gráfico es un boxplot que muestra la distribución de volatilidad diaria agrupada por mes. Noviembre destaca consistentemente como el mes de mayor volatilidad con medianas más altas y outliers extremos, mientras que los meses de verano tienden a mostrar menor volatilidad en promedio. La presencia de outliers en prácticamente todos los meses confirma la naturaleza inherentemente volátil del mercado crypto, y el hecho de que la volatilidad no haya disminuido con el tiempo sugiere que el asset mantiene su carácter especulativo.

Resumen de Calidad:

El dataset final contiene 1,460 muestras que cubren el período desde el 24 de enero de 2022 hasta el 22 de enero de 2026. No se encontraron días faltantes en el rango temporal, duplicados por datetime, valores nulos en columnas OHLCV, ni violaciones de las reglas de coherencia de precios. Los datos de SOLUSD son de alta calidad y están listos para ser cargados en S3 y utilizados en los siguientes sprints del proyecto para análisis de tendencias, procesamiento batch, y alimentación de dashboards de visualización.

2. Respuesta a HU-2: Diseño de la Arquitectura de Almacenamiento

Hemos diseñado una arquitectura **Data Lake** sobre Amazon S3, priorizando la estructura lógica de carpetas (partitioning) sobre la multiplicidad de buckets para facilitar la gestión de todo el sistema.

2.1. Estrategia de Bucket Único

En lugar de fragmentar la información en múltiples buckets, hemos implementado un **Bucket Centralizado**.

- **Nombre del Bucket:** `trade-data-big-daddyks-trading`
- **Región:** `eu-south-2` (España) para tener los permisos necesarios que tiene la cuenta que tenemos.
- **Justificación:** Hemos decidido tener un bucket central/principal porque queremos centralizar la entrada de datos y simplificar la gestión de permisos, permitiendo así poder asignar permisos únicamente a ese bucket. También porque esta estructura reduce la complejidad operativa, y es beneficioso para el siguiente Sprint.

2.2. Jerarquía de Objetos (Partitioning)

Dentro del bucket central de trading, los datos se organizan siguiendo un esquema de particionado físico compatible con **Apache Hive/Spark**. Tenemos carpetas organizadas por criptomonedas(en este caso solo una), años y meses que contienen ficheros con la siguiente forma:

- **Estructura de Clave (Key):**
`{Asset=CRIPTO}/{Year=YYYY}/{month=MM}/data.csv`
- **Ejemplo Real:** `Asset=SOLUSD/Year=2024/month=03/data.csv`
- **Justificación:**
 - **Eficiencia de Lectura (Pruning):** Al separar por Activo > Año > Mes, los futuros procesos de Spark pueden leer solo las carpetas necesarias (ej. "Solo datos de SOLUSD de 2024") sin escanear todo el bucket, lo cual es más eficiente. Además, no estamos incurriendo en sobre particionamiento, lo cual sí que podría pasar si también dividiéramos por semanas, días, horas, etc.
 - **Atomicidad:** Separar por meses evita manejar archivos CSV enormes que son difíciles de procesar o transferir.

2.3. Formato de Archivo

- **Tipo:** CSV (Comma Separated Values).
 - **Schema:** `datetime,symbol, open, high, low, close, volume`.
-

3. Implementación Técnica (Lógica de **complete.py**)

Para la orquestación del proceso ETL, hemos desarrollado un script en Python que va más allá de una simple descarga. Hemos implementado un pipeline que desarrolla la lógica de **Ingeniería de Datos** para hacer el proceso completo y secuencial tanto de descarga como de ingesta. Además, todo esto se realiza de manera inteligente ya que hacemos uso de una memoria caché, que permite que solo tengamos que descargar los datos que nos hagan falta (teniendo en cuenta qué día es hoy y qué día se hizo la última descarga de datos) y no volvamos a descargar aquellos registros de las fechas que ya tenemos en nuestro bucket.

3.1. Smart Caching y Carga Incremental

Hemos implementado una lógica de "caché de estado" consultando directamente a S3 antes de descargar nada.

- **Función:** `infer_last_ingested_from_s3`
- **Lógica:** El script verifica cuál es el último archivo subido a S3 para cada activo.
 - Escenario A (Primera ejecución): No encuentra datos -> Descarga los 4 años completos, desde el día actual que lo ejecutamos.
 - Escenario B (Ejecución diaria): Encuentra que el último dato es de ayer -> Calcula el delta (día de hoy menos último día disponible en el sistema) y descarga solo el día de hoy.
- **Beneficio:** Reduce el tiempo de ejecución, que podría ser hasta de minutos si tenemos muchos años y muchas criptomonedas, pero queda reducido a segundos, logrando así reducir drásticamente el coste computacional de tener que quitar todo y volver a cargarlo, y también evita posibles bloqueos por Rate Limiting en la API de TradingView.

3.2. Gestión Automática del Ciclo de Vida (Retention)

El script actúa como su propio "Garbage Collector" para cumplir la política de los 4 años estrictos.

- **Función:** `retention_cleanup_months`
- **Lógica:** Antes de ingerir, el script lista las particiones existentes. Si se detectan carpetas (meses) que quedan fuera de la ventana de retención (más antiguas de 4 años), las elimina automáticamente. No obstante esto se ha configurado para poder decidir si queremos tener ese marco temporal de los cuatro años o mantener todo lo anterior y simplemente ir cargando nuevos datos. Se puede modificar con un simple booleano.
- **Beneficio:** Mantiene el Data Lake limpio y optimiza los costes de almacenamiento S3 sin intervención manual. Además es fácilmente escalable y modificable por si en el futuro queremos obtener una funcionalidad diferente.

3.3. Idempotencia en Infraestructura

- **Función:** `ensure_bucket_exists`
 - **Lógica:** El código verifica la existencia del bucket y, si no existe, lo crea aplicando la restricción regional (`LocationConstraint: eu-south-2`).
 - **Beneficio:** Permite desplegar el proyecto en un entorno limpio sin configuración manual previa, garantizando que la infraestructura se autogestiona (Infrastructure as Code imperativo).
-

4. Resultados y Evidencias

4.1. Bucket y Estructura en S3

A continuación se muestra el bucket creado en la región España y la jerarquía de carpetas generada automáticamente por el script complete.py:

Buckets de uso general

Todas las regiones de AWS

Buckets de directorio

Buckets de uso general (1)

Información

Copiar ARN

Vaciar

Eliminar

Crear bucket

Los buckets son contenedores de datos almacenados en S3.

Q

Buscar buckets por nombre

< 1 >

Nombre

▲

Región de AWS

▼

Fecha de creación

▼

☐

[trade-data-big-daddyks-trading](#)

Europa (España) eu-south-2

28 Jan 2026 7:33:35 PM CET

Objetos (1)

Copiar URI de S3

Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Para que los usuarios obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita.

Q

Buscar objetos por prefijo

☐

Nombre

▲

Tipo

☐

[Asset=SOLUSD/](#)

Carpeta

Objetos (5)

Copiar URI de S3

Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Para que los usuarios obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita.

Q

Buscar objetos por prefijo

☐

Nombre

▲

Tipo

☐

[year=2022/](#)

Carpeta

☐

[year=2023/](#)

Carpeta

☐

[year=2024/](#)

Carpeta

☐

[year=2025/](#)

Carpeta

☐

[year=2026/](#)

Carpeta

Objetos (12)



Copiar URI de S3

Los objetos son las entidades fundamentales que se almacenan en /
obtienen acceso a sus objetos, tendrá que concederles permisos de

Buscar objetos por prefijo

☐	Nombre	▲	Tipo
☐	month=01/		Carpeta
☐	month=02/		Carpeta
☐	month=03/		Carpeta
☐	month=04/		Carpeta
☐	month=05/		Carpeta
☐	month=06/		Carpeta
☐	month=07/		Carpeta
☐	month=08/		Carpeta
☐	month=09/		Carpeta
☐	month=10/		Carpeta
☐	month=11/		Carpeta
☐	month=12/		Carpeta

En este caso aparecen 5 años cuando podríamos pensar que solo debería haber 4, porque en 2026 únicamente tenemos datos del mes de enero hasta día de hoy, y en 2022 tenemos todo. A medida que pase el tiempo, si ejecutamos el script de nuevo por ejemplo en marzo, el sistema se encargará de descargar únicamente los datos necesarios (de enero a marzo), y dependiendo de si queremos mantener la integridad de solo tener 4 años o no (controlado con el booleano comentado en apartados anteriores), eliminará los meses de enero y febrero de 2022.

4.2. Validación de Datos

Muestra del contenido de un archivo CSV descargado ([SOLUSD_2024-01.csv](#)) para verificar integridad:

	A	B	C	D	E	F	G
1	Column1	Column2	Column3	Column4	Column5	Column6	Column7
2	datetime	symbol	open	high	low	close	volume
3	2022-01-01 01:00:00+00:00	BINANCE:SOLUSD	170.09	180.97	169.08	179.21	145171.0372246
4	2022-01-02 01:00:00+00:00	BINANCE:SOLUSD	179.03	181.03	172.81	176.48	108964.78135544
5	2022-01-03 01:00:00+00:00	BINANCE:SOLUSD	176.3	177.61	166.47	170.02	171111.71189762
6	2022-01-04 01:00:00+00:00	BINANCE:SOLUSD	169.92	175.46	164.05	167.73	228746.37171606
7	2022-01-05 01:00:00+00:00	BINANCE:SOLUSD	167.97	172.5	145.13	154.52	280814.53682443
8	2022-01-06 01:00:00+00:00	BINANCE:SOLUSD	154.63	156.08	145.69	150.32	230506.53941118
9	2022-01-07 01:00:00+00:00	BINANCE:SOLUSD	150.1	150.67	132.86	136.4	360553.23962484
10	2022-01-08 01:00:00+00:00	BINANCE:SOLUSD	136.61	148.76	132.53	142.19	382668.22875569
11	2022-01-09 01:00:00+00:00	BINANCE:SOLUSD	142.13	148.78	137.38	140.85	238622.01177914
12	2022-01-10 01:00:00+00:00	BINANCE:SOLUSD	140.91	144.23	127.79	136.0	281925.68749141
13	2022-01-11 01:00:00+00:00	BINANCE:SOLUSD	135.89	144.52	132.45	140.22	206324.78141842
14	2022-01-12 01:00:00+00:00	BINANCE:SOLUSD	140.4	155.44	138.18	151.6	365358.4446395
15	2022-01-13 01:00:00+00:00	BINANCE:SOLUSD	151.55	159.73	144.4	146.13	287935.02632533
16	2022-01-14 01:00:00+00:00	BINANCE:SOLUSD	146.18	150.8	144.62	145.88	82582.53300941
17	2022-01-15 01:00:00+00:00	BINANCE:SOLUSD	146.28	149.41	144.07	147.71	169007.29
18	2022-01-16 01:00:00+00:00	BINANCE:SOLUSD	147.7	152.03	146.21	148.08	139298.4
19	2022-01-17 01:00:00+00:00	BINANCE:SOLUSD	148.17	148.37	137.23	139.92	173826.7
20	2022-01-18 01:00:00+00:00	BINANCE:SOLUSD	140.05	142.81	134.75	141.29	156350.74
21	2022-01-19 01:00:00+00:00	BINANCE:SOLUSD	141.48	142.72	132.92	135.26	178377.12

4.3. Logs de Ejecución

Salida de consola del script demostrando la lógica incremental (detectando datos previos):

```
C:\Users\Principal\Documents\ICAI\OneDrive - Unive
=== TradeData Batch Ingestion ===
Bucket: trade-data-big-daddyks-trading
Region: eu-south-2
Exchange: BINANCE
DRY_RUN: False
Retention cleanup: True (months < 2022-01-01)

--- Asset: SOLUSD ---
Last ingested: 2025-12-31
Need: 2026-01-01 -> 2026-01-29
Fetch from: 2026-01-01 -> 2026-01-29
Expecting value: line 1 column 1 (char 0)
Uploaded partitions: 1

Done.
```

Esta es la salida que obtenemos tras intentar descargar todos los datos, habiendo borrado el mes de enero de 2026. Como se puede observar, en vez de descargar los 49 meses de golpe, solo se descarga el mes faltante, tras hacer los cálculos necesarios para ubicar exactamente los datos que faltan desde la fecha de ejecución actual hasta la última fecha de ejecución.

En cambio, si borramos todos los datos (el bucket central entero) o ejecutamos el pipeline por primera vez, veremos que se nos descargan absolutamente todos los datos. De esta forma podemos ver la comparación entre los distintos comportamientos del sistema automatizado, que siempre toma la opción más eficiente, teniendo en cuenta qué datos ya hay descargados y cuáles faltan. Veamos la salida que se obtiene en la terminal si ejecutamos bajo este segundo contexto:

```
C:\Users\Principal\Documents\ICAI\OneDrive - Uni
=== TradeData Batch Ingestion ===
Bucket: trade-data-big-daddyks-trading
Region: eu-south-2
Exchange: BINANCE
DRY_RUN: False
Retention cleanup: True (months < 2022-01-01)

--- Asset: SOLUSD ---
Last ingested: None
Need: 2022-01-30 -> 2026-01-29
Fetch from: 2022-01-01 -> 2026-01-29
Expecting value: line 1 column 1 (char 0)
Uploaded partitions: 49

Done.
```

5. Conclusión

Se ha completado la fase de ingesta histórica (4 años) cumpliendo las HU-1 y HU-2. Disponemos de un sistema automatizado que:

1. Ingesta datos de TradingView/Binance.
2. Gestiona la infraestructura S3 automáticamente.
3. Optimiza descargas mediante detección incremental y el uso de memoria caché.
4. Limpia datos obsoletos.
5. Permite eliminar los buckets que se deseen ejecutando el script `deletion.py` .